

**Федеральное государственное образовательное бюджетное учреждение  
высшего образования**

**«ФИНАНСОВЫЙ УНИВЕРСИТЕТ ПРИ ПРАВИТЕЛЬСТВЕ РФ»**

**Департамент анализа данных и машинного обучения**

**Отчет по практике №5**

**по дисциплине «эконометрика»**

Студента группы ПМ23-1

Факультета  
информационных  
технологий и анализа  
больших данных

Тищенко И.С.

Преподаватель

Михайлова С.С.

Москва 2024

Задание 1: Представить наилучшую модель Филлипса

Из предыдущей работы возьмем лучшую модель - полиномиальное преобразование 10-ой степени. Выведем статистику этой модели:

OLS Regression Results

```
=====
Dep. Variable:          y  R-squared:          0.956
Model:                  OLS  Adj. R-squared:      0.936
Method:                 Least Squares  F-statistic:      48.00
Date:                   Thu, 14 Nov 2024  Prob (F-statistic):  1.33e-12
Time:                   12:05:32  Log-Likelihood:      4.7808
No. Observations:       33  AIC:                  12.44
Df Residuals:           22  BIC:                  28.90
Df Model:               10
Covariance Type:        nonrobust
=====
```

```
=====
              coef  std err      t  P>|t|  [0.025  0.975]
-----
const         0.6960   0.150   4.638   0.000   0.385   1.007
x1          -0.9601   0.554  -1.734   0.097  -2.109   0.188
x2           1.9447   1.337   1.454   0.160  -0.828   4.718
x3           2.5101   2.573   0.976   0.340  -2.826   7.846
x4          -6.8714   3.241  -2.120   0.045  -13.592  -0.150
x5          -0.9790   4.336  -0.226   0.823  -9.971   8.013
=====
```

x6	5.4066	2.622	2.062	0.051	-0.030	10.844
x7	-0.5702	3.247	-0.176	0.862	-7.304	6.164
x8	-1.4159	0.631	-2.243	0.035	-2.725	-0.107
x9	0.3038	0.906	0.335	0.741	-1.575	2.183
x10	0.0438	0.230	0.191	0.851	-0.433	0.521

=====

Omnibus: 20.711 Durbin-Watson: 3.113

Prob(Omnibus): 0.000 Jarque-Bera (JB): 79.381

Skew: -0.938 Prob(JB): 5.79e-18

Kurtosis: 10.363 Cond. No. 5.08e+04


=====

Задание 2: Провести тесты на автокорреляцию (графический, метод рядов, критерий Дарбина-Уотсона, коэффициент автокорреляции) (на уровне значимости 0,05)

### Графический тест

Сильная автокорреляция на малых лагах (например, на лаге 1) может указывать на зависимость между соседними значениями остатков. Это может свидетельствовать о недоучтенных временных зависимостях, что нарушает предположение о независимости остатков в регрессионной модели.

Все значения ACF в пределах доверительных интервалов вокруг нуля предполагают, что остатковая автокорреляция отсутствует, и остатки можно считать независимыми. Доверительный интервал строится для того, чтобы учесть случайные колебания.



## Метод рядов

Метод рядов (или тест серий) — это статистический тест, который проверяет случайность последовательности данных, таких как остатки модели. Этот тест определяет, есть ли в последовательности какие-то паттерны, что может указывать на автокорреляцию.

### Основная идея метода рядов

Метод рядов анализирует последовательность знаков (положительных и отрицательных) остатков модели, определяя так называемые ряды. Ряд — это последовательность положительных или отрицательных остатков, которая заканчивается, когда знак остатка меняется. Если остатки действительно случайны и независимы, то количество таких рядов в последовательности будет приближаться к случайному значению, определяемому теорией вероятностей.

### Как работает метод рядов?

1. Определение рядов: Последовательность остатков разделяется на ряды, которые представляют собой непрерывные участки положительных или отрицательных значений. Например, если последовательность остатков выглядит так: “[+, +, -, -, +, -]”, то в ней 4 ряда (2 положительных и 2 отрицательных).

2. Подсчет числа рядов: Подсчитывается общее количество рядов и количество положительных и отрицательных остатков.

3. Проверка случайности: На основе числа положительных и отрицательных рядов можно вычислить ожидаемое количество рядов при условии, что остатки независимы. Затем сравнивается фактическое количество рядов с ожидаемым.

4. Выводы: Если фактическое количество рядов значительно отличается от ожидаемого, можно предположить, что остатки не случайны и в них присутствует автокорреляция.

### Формула метода рядов

Для последовательности длиной  $N$  с  $N_+$  положительными и  $N_-$  отрицательными значениями, ожидаемое количество рядов  $E(R)$  вычисляется как:

$$E(R) = \frac{2N_+N_-}{N} + 1$$

Дисперсия количества рядов  $\text{Var}(R)$  рассчитывается как:

$$\text{Var}(R) = \frac{2N_+N_-(2N_+N_- - N)}{N^2(N - 1)}$$

Для проверки гипотезы используется нормализованная статистика:

$$Z = \frac{R - E(R)}{\sqrt{\text{Var}(R)}}$$

Если  $|Z|$  больше критического значения нормального распределения (например, 1.96 при уровне значимости 0,05), гипотеза о случайности отклоняется.

#### Интерпретация

- Если гипотеза о случайности отклоняется, это говорит о наличии автокорреляции в остатках.

- Если гипотеза о случайности не отклоняется, можно считать, что остатки случайны и независимы.

Метод рядов помогает быстро оценить, нарушено ли предположение о случайности остатков, что может указывать на недостатки модели или необходимость ее уточнения.

Используя этот метод, получим вывод:

Гипотеза о случайности не отклоняется, автокорреляции нет.

## Критерий Дарбина-Уотсона

Критерий Дарбина-Уотсона (DW) — это статистический тест, который проверяет наличие автокорреляции первого порядка в остатках линейной регрессионной модели. Автокорреляция остатков может указывать на то, что модель не учла какую-то структуру в данных, что может снизить точность прогнозов и валидность выводов.

### Основная идея критерия Дарбина-Уотсона

Критерий Дарбина-Уотсона определяет, насколько остатки  $e_t$  в модели связаны со значениями на предыдущих шагах  $e_{t-1}$ . Если остатки модели являются случайными (без автокорреляции), их значения на разных шагах времени должны быть независимы друг от друга.

### Формула критерия Дарбина-Уотсона

Статистика Дарбина-Уотсона  $d$  вычисляется по формуле:

$$d = \frac{\sum_{t=2}^T (e_t - e_{t-1})^2}{\sum_{t=1}^T e_t^2}$$

где:

- $e_t$  — остаток (ошибка) модели на шаге  $t$ ,
- $T$  — общее количество наблюдений.

Значение  $d$  находится в диапазоне от 0 до 4.

### Интерпретация значения $d$

- Если  $d \approx 2$ : Это означает, что автокорреляция отсутствует, остатки случайны.
- Если  $d < 2$ : Есть положительная автокорреляция, т.е. положительные остатки с большей вероятностью следуют за положительными, а отрицательные за отрицательными.
- Если  $d > 2$ : Есть отрицательная автокорреляция, когда положительные и отрицательные значения чередуются чаще, чем это было бы случайно.

### Критические значения

Для теста на значимость используется таблица критических значений  $d_L$  и  $d_U$  (нижнего и верхнего порогов), которые зависят от числа наблюдений и количества регрессоров. Интерпретация:

- $d < d_L$ : Наблюдается значительная положительная автокорреляция.
- $d > 4 - d_L$ : Наблюдается значительная отрицательная автокорреляция.
- $d_U < d < 4 - d_U$ : Автокорреляции нет.
- $d_L \leq d \leq d_U$  или  $4 - d_U \leq d \leq 4 - d_L$ : Результат не определен, и требуется дополнительная проверка.

#### Пример интерпретации

1. Если  $dw\_stat \approx 2$ : Остатки случайны, автокорреляции нет, и модель хорошо описывает данные.
2. Если  $dw\_stat < 2$ : Положительная автокорреляция. Это может означать, что модель не учла какие-то временные зависимости, и можно рассмотреть модели, учитывающие структуру автокорреляции (например, авторегрессионные модели).
3. Если  $dw\_stat > 2$ : Отрицательная автокорреляция. Это редко встречается в эконометрических данных, но может наблюдаться в некоторых временных рядах, где данные колеблются вокруг среднего значения.

Критерий Дарбина-Уотсона позволяет выявить автокорреляцию в остатках модели, помогая оценить качество регрессионной модели и понять, требуется ли добавить дополнительные переменные или перестроить модель.

Используя этот метод, получим вывод:

Статистика Дарбина-Уотсона: 3.113136974542018

Отрицательная автокорреляция. Это редко встречается в эконометрических данных, но может наблюдаться в некоторых временных рядах, где данные колеблются вокруг среднего значения.



## Коэффициент автокорреляции

Коэффициенты автокорреляции (ACF, Autocorrelation Function) измеряют, насколько текущие значения временного ряда зависят от его прошлых значений на разных лагах (шагов смещения во времени). Они показывают степень корреляции между значениями ряда на разных временных интервалах, помогая понять наличие и характер временных зависимостей.

Как рассчитываются коэффициенты автокорреляции?

Для временного ряда  $y_t$  коэффициент автокорреляции на лаге  $k$  ( $\rho_k$ ) можно рассчитать следующим образом:

$$\rho_k = \frac{\sum_{t=k+1}^T (y_t - \bar{y})(y_{t-k} - \bar{y})}{\sum_{t=1}^T (y_t - \bar{y})^2}$$

где:

- $y_t$  — значение временного ряда в момент времени  $t$ ,
- $\bar{y}$  — среднее значение временного ряда,
- $T$  — общее количество наблюдений,
- $k$  — лаг.

Интерпретация коэффициентов автокорреляции

1. Если  $\rho_k \approx 0$  на всех лагах  $k$ , это говорит о том, что значения временного ряда не зависят от предыдущих значений, и остатки случайны. Такой временной ряд не содержит автокорреляции.

2. Если  $\rho_k > 0$  на малых значениях  $k$  (например,  $k = 1, 2, 3$ ), то в данных присутствует положительная автокорреляция. Это означает, что высокие значения ряда (например, большие остатки) с большей вероятностью следуют за высокими значениями, а низкие значения — за низкими.

3. Если  $\rho_k < 0$  на малых значениях  $k$ , это указывает на отрицательную автокорреляцию, когда значения временного ряда

чередуются — высокое значение имеет тенденцию следовать за низким, и наоборот.

4. Постепенное затухание автокорреляции (медленное снижение значений  $\rho_k$ ) на больших лагах может свидетельствовать о наличии долгосрочной структуры или сезонности в данных.

Как использовать ACF на практике?

1. Оценка случайности остатков: Если остатки модели не автокоррелированы, большинство значений ACF для остатков будут находиться внутри доверительных интервалов.

2. Выбор модели временного ряда: ACF помогает определить подходящую модель для анализа временных рядов. Например:

- Если автокорреляция значима только на первом лаге, можно рассмотреть модель AR(1).

- Если автокорреляция затухает медленно, возможны сложные модели, такие как ARIMA.

3. Выявление сезонности: Если наблюдаются пики автокорреляции через регулярные интервалы, это может указывать на сезонность.

Коэффициенты автокорреляции являются важным инструментом в анализе временных рядов, позволяя глубже понять их структуру и выявить возможные временные зависимости.

Коэффициенты автокорреляции (ACF): 1.00000000e+00;  
-5.56580577e-01; 1.90015721e-01; -1.42213720e-01;  
-4.25729145e-02; -9.50581422e-05; 4.92299788e-02; 2.64304219e-02;  
-5.01816572e-03; -4.20594376e-02; -6.76395648e-03; 2.44650998e-03;  
3.24388298e-02; 2.85135661e-02; -2.17563514e-02; 3.52110148e-02;

Чтобы интерпретировать этот ряд коэффициентов автокорреляции (ACF), нужно рассмотреть значения автокорреляций на каждом лаге и

понять, есть ли какие-то значимые паттерны, указывающие на структуру временных зависимостей в данных.

Интерпретация коэффициентов автокорреляции:

1. Лаг 0: Коэффициент автокорреляции равен 1.0, так как это корреляция ряда с самим собой. Это значение всегда равно 1 и используется в качестве отправной точки для сравнения следующих лагов.

2. Лаг 1: Коэффициент автокорреляции составляет  $-0.556$ . Значительное отрицательное значение на первом лаге указывает на сильную отрицательную автокорреляцию. Это означает, что значения временного ряда имеют тенденцию чередоваться: высокие значения следуют за низкими, и наоборот. Такая структура автокорреляции характерна для данных, в которых присутствует "чередование" значений.

3. Лаги 2–3: Коэффициенты 0.190 и  $-0.142$  показывают некоторую слабую положительную и отрицательную автокорреляцию на втором и третьем лагах. Это может указывать на краткосрочные паттерны или на то, что влияние автокорреляции быстро затухает после первого лага.

4. Лаги 4 и далее: Коэффициенты на этих лагах имеют низкие значения (менее  $\pm 0.05$ ) и близки к нулю. Это говорит о том, что на этих лагах нет значимой автокорреляции, и временная зависимость между значениями ряда после третьего лага практически отсутствует.

5. Небольшие колебания на больших лагах: Некоторые лаги имеют небольшие значения автокорреляции, как, например, 0.049 на шестом лаге и 0.035 на 15-м лаге. Такие значения в пределах доверительного интервала, вероятно, не значимы и могут быть случайными. В целом, это свидетельствует о том, что временная зависимость в остатках после третьего лага отсутствует.

Итоговая интерпретация:

- Основная автокорреляция в этом ряду сосредоточена на первом лаге с сильным отрицательным значением, что указывает на чередование значений. Возможно, моделью не учтена какая-то структура, которая приводит к такой автокорреляции.

- Быстрое затухание автокорреляции после первых нескольких лагов говорит о том, что зависимость между значениями временного ряда исчезает довольно быстро.

Задание 3: Построить авторегрессионную схему 1-ого порядка AR(1) (определив коэффициент авторегрессии с помощью: Дарбина-Уотсона, методами: Кохрейна-Оркатта, Хилдрета -Лу)

### Метод Хилдрета-Лу

Метод Хилдрета-Лу — это один из способов корректировки регрессионной модели, если в её остатках присутствует автокорреляция первого порядка. Этот метод, в отличие от метода Кохрейна-Оркатта, не является итерационным, а представляет собой метод подбора параметра автокорреляции  $\rho$  для корректировки модели.

#### Основная идея метода Хилдрета-Лу

Метод Хилдрета-Лу заключается в том, чтобы перебором найти такое значение параметра  $\rho$ , которое минимизирует сумму квадратов преобразованных остатков. Метод используется для устранения автокорреляции первого порядка, когда она выражается через авторегрессионное уравнение:

$$e_t = \rho e_{t-1} + u_t$$

где  $e_t$  — остаток модели в момент времени  $t$ ,  $\rho$  — коэффициент автокорреляции, который подбирается, и  $u_t$  — белый шум.

#### Пошаговый алгоритм метода Хилдрета-Лу

1. Выбор диапазона значений для  $\rho$ : Определяется диапазон возможных значений для  $\rho$ , например от -1 до 1, с шагом (например, 0.01 или 0.05).

2. Трансформация данных: Для каждого значения  $\rho$  в этом диапазоне преобразовывают зависимую переменную  $Y_t$  и независимые переменные  $X_t$  по следующей схеме:

- $Y'_t = Y_t - \rho Y_{t-1}$
- $X'_t = X_t - \rho X_{t-1}$

3. Построение регрессии на преобразованных данных: Оценивается регрессия для каждой пары  $Y'_t$  и  $X'_t$  для каждого значения  $\rho$  в выбранном диапазоне. На каждом шаге сохраняется сумма квадратов остатков.

4. Выбор оптимального  $\rho$ : Оптимальным значением  $\rho$  считается то, которое минимизирует сумму квадратов преобразованных остатков.

5. Окончательная оценка модели: После определения оптимального значения  $\rho$  выполняется окончательная оценка регрессионной модели с применением найденного коэффициента автокорреляции.

### Преимущества и недостатки метода Хилдрета-Лу

- Преимущества:
  - Простота реализации, поскольку не требует итераций после нахождения оптимального  $\rho$ .
  - Подходит для моделей, где автокорреляция первого порядка выражена, и есть уверенность в выборе диапазона значений  $\rho$ .
- Недостатки:
  - Зависимость от выбора диапазона  $\rho$ : если диапазон выбран неправильно, решение может оказаться неэффективным.
  - Метод предполагает линейную автокорреляцию только первого порядка и может оказаться менее точным, если данные имеют более сложные временные зависимости.

### Заключение

Метод Хилдрета-Лу — это простой и понятный способ устранения автокорреляции первого порядка. Он подходит для моделей, где предположение об автокорреляции первого порядка обосновано. Однако точность метода сильно зависит от выбора диапазона и шага изменения  $\rho$ , что может потребовать дополнительных проверок на практике.

Оптимальное значение rho: -0.5699999999999996

Модель со схемой AR(1):

OLS Regression Results

=====

Dep. Variable:	y	R-squared:	0.985
Model:	OLS	Adj. R-squared:	0.978
Method:	Least Squares	F-statistic:	137.9
Date:	Thu, 14 Nov 2024	Prob (F-statistic):	7.84e-17
Time:	11:59:31	Log-Likelihood:	10.337
No. Observations:	32	AIC:	1.326
Df Residuals:	21	BIC:	17.45
Df Model:	10		
Covariance Type:	nonrobust		

	coef	std err	t	P> t	[0.025	0.975]
x1	0.6949	0.085	8.175	0.000	0.518	0.872
x2	-1.0946	0.331	-3.303	0.003	-1.784	-0.405
x3	1.8644	0.825	2.259	0.035	0.148	3.581
x4	3.2730	1.629	2.010	0.057	-0.114	6.660
x5	-6.5671	2.109	-3.114	0.005	-10.953	-2.181
x6	-2.3254	2.882	-0.807	0.429	-8.318	3.667
x7	5.2214	1.789	2.919	0.008	1.501	8.941
x8	0.4139	2.258	0.183	0.856	-4.283	5.110
x9	-1.5166	0.446	-3.399	0.003	-2.444	-0.589
x10	0.0449	0.658	0.068	0.946	-1.324	1.414
x11	0.1188	0.169	0.701	0.491	-0.233	0.471

Omnibus:	20.080	Durbin-Watson:	2.135
Prob(Omnibus):	0.000	Jarque-Bera (JB):	36.434
Skew:	-1.383	Prob(JB):	1.23e-08
Kurtosis:	7.435	Cond. No.	4.88e+04

Оптимальное значение  $\rho = -0.57$ , полученное по методу Хилдрета-Лу, указывает на отрицательную автокорреляцию остатков в регрессионной модели. Это означает, что если остаток в одном периоде высок, то в следующем он, вероятно, будет низким, и наоборот. Такая чередующаяся зависимость между остатками свидетельствует о том, что в данных присутствует цикличность или "отскакивающий" паттерн, когда

изменения в одну сторону сменяются изменениями в противоположную сторону.

### Выводы и интерпретация

1. Чередующаяся зависимость: Отрицательная автокорреляция (-0.57) говорит о том, что в остатках присутствует заметная чередующаяся зависимость. Это часто встречается в данных с сезонными или циклическими паттернами, где наблюдаются регулярные изменения, которые "сглаживают" друг друга.

2. Эффективность корректировки: Теперь, с учетом найденного значения  $\rho$ , модель скорректирована таким образом, чтобы устранить автокорреляцию остатков первого порядка. Это должно повысить надежность коэффициентов регрессии, так как больше не будет систематической зависимости в остатках, что устраняет одну из потенциальных проблем модели.

3. Рекомендации: Отрицательная автокорреляция в остатках может сигнализировать о недоучтенных сезонных эффектах или других временных факторах. Если это применимо к данным, стоит рассмотреть добавление переменных, отражающих сезонные или временные колебания, чтобы дополнительно повысить точность модели.



## Метод Кохрейна-Оркатта

Метод Кохрейна-Оркатта — это итерационный метод, который применяется для устранения автокорреляции первого порядка в регрессионных моделях. Он используется, когда остатки модели демонстрируют положительную автокорреляцию, и позволяет скорректировать параметры модели, чтобы сделать её более точной и избавиться от автокорреляции.

### Основная идея метода Кохрейна-Оркатта

Метод Кохрейна-Оркатта заключается в преобразовании исходной модели так, чтобы устранить автокорреляцию в остатках. Он предполагает, что остатки модели  $e_t$  связаны по схеме авторегрессии первого порядка (AR(1)):

$$e_t = \rho e_{t-1} + u_t$$

где:

- $\rho$  — коэффициент автокорреляции, который нужно оценить,
- $u_t$  — белый шум, который является случайным и независимым от предыдущих значений.

Метод Кохрейна-Оркатта трансформирует исходные уравнения регрессии таким образом, чтобы устранить автокорреляцию остатков.

### Пошаговый алгоритм метода Кохрейна-Оркатта

1. Оценка исходной модели: Построить исходную регрессионную модель и рассчитать коэффициент автокорреляции первого порядка  $\rho$  с помощью, например, критерия Дарбина-Уотсона или автокоррелограммы.

2. Трансформация переменных: Применить следующую трансформацию к каждому уравнению модели:

- Для зависимой переменной  $Y_t$ :

$$Y'_t = Y_t - \rho Y_{t-1}$$

- Для каждой независимой переменной  $X_t$ :  $X'_t = X_t - \rho X_{t-1}$

В результате получается уравнение для преобразованных переменных:

$$Y'_t = \beta_0(1 - \rho) + \beta_1 X'_t + \varepsilon'_t$$

3. Переоценка модели: Построить регрессионную модель на основе преобразованных переменных  $Y'_t$  и  $X'_t$  и найти новые оценки коэффициентов.

4. Итерация: Пересчитать коэффициент автокорреляции  $\rho$  на основе новых остатков и повторить шаги 2 и 3, пока значения коэффициентов не перестанут значительно изменяться.

Преимущества и недостатки метода Кохрейна-Оркатта

- Преимущества:

- Позволяет избавиться от автокорреляции первого порядка, улучшая точность модели.

- Метод прост в реализации и подходит для небольших наборов данных с автокорреляцией первого порядка.

- Недостатки:

- Требуется многократных итераций, которые могут быть ресурсоемкими.

- Если автокорреляция в данных не ограничивается первым порядком, метод может быть менее эффективен.

Заключение

Метод Кохрейна-Оркатта помогает эффективно скорректировать модель, если в данных присутствует автокорреляция первого порядка. Благодаря итеративной процедуре и трансформации переменных метод устраняет временную зависимость остатков, делая модель более корректной.

Коэффициент автокорреляции rho: -0.42414789487160603

Модель со схемой AR(1):

OLS Regression Results

=====

Dep. Variable:	y	R-squared:	0.985
Model:	OLS	Adj. R-squared:	0.978
Method:	Least Squares	F-statistic:	137.9
Date:	Thu, 14 Nov 2024	Prob (F-statistic):	7.84e-17
Time:	11:59:31	Log-Likelihood:	10.337
No. Observations:	32	AIC:	1.326
Df Residuals:	21	BIC:	17.45
Df Model:	10		
Covariance Type:	nonrobust		

	coef	std err	t	P> t	[0.025	0.975]
x1	0.6949	0.085	8.175	0.000	0.518	0.872
x2	-1.0946	0.331	-3.303	0.003	-1.784	-0.405
x3	1.8644	0.825	2.259	0.035	0.148	3.581
x4	3.2730	1.629	2.010	0.057	-0.114	6.660
x5	-6.5671	2.109	-3.114	0.005	-10.953	-2.181
x6	-2.3254	2.882	-0.807	0.429	-8.318	3.667
x7	5.2214	1.789	2.919	0.008	1.501	8.941
x8	0.4139	2.258	0.183	0.856	-4.283	5.110
x9	-1.5166	0.446	-3.399	0.003	-2.444	-0.589
x10	0.0449	0.658	0.068	0.946	-1.324	1.414
x11	0.1188	0.169	0.701	0.491	-0.233	0.471

Omnibus:	20.080	Durbin-Watson:	2.135
Prob(Omnibus):	0.000	Jarque-Bera (JB):	36.434
Skew:	-1.383	Prob(JB):	1.23e-08
Kurtosis:	7.435	Cond. No.	4.88e+04

Коэффициент автокорреляции  $\rho = -0.424$ , полученный по методу Кохрейна-Оркатта, также указывает на отрицательную автокорреляцию в остатках модели, но с меньшей величиной автокорреляции по сравнению с предыдущим результатом (-0.57 по методу Хилдрета-Лу).

Выводы и интерпретация:

1. Отрицательная автокорреляция: Значение  $\rho = -0.424$  подтверждает, что остатки модели имеют отрицательную автокорреляцию. Это означает, что высокие значения остатков с большой вероятностью будут следовать за низкими значениями и наоборот. Такая динамика может свидетельствовать о наличии циклических или колеблющихся паттернов в данных.

2. Сравнение с методом Хилдрета-Лу: Полученное значение  $\rho$  по методу Кохрейна-Оркатта ( $-0.424$ ) несколько меньше, чем по методу Хилдрета-Лу ( $-0.57$ ). Это может означать, что подходы к оценке автокорреляции дали немного разные результаты, что является нормальной ситуацией в эконометрике, поскольку оба метода имеют свои особенности и нюансы.

3. Корректировка модели: В обоих случаях, с учетом автокорреляции в остатках, корректировка модели (например, с использованием авторегрессионных моделей или модели ARIMA) будет полезной для улучшения точности предсказаний.

4. Уровень автокорреляции: Значение  $\rho = -0.424$  не слишком велико, но оно указывает на заметную автокорреляцию, которую стоит учитывать при дальнейшей обработке данных. Это значение подтверждает, что в данных есть некоторый циклический характер, но автокорреляция достаточно умеренная.

Таким образом, коэффициент  $\rho = -0.424$  подтверждает наличие отрицательной автокорреляции в данных, и для повышения точности модели стоит рассматривать корректировки и учет этих временных зависимостей.